Lenguaje de máquina: datos   

95.57/75.03 Organización del computador

Docentes: Patricio Moreno y Adeodato Simó

2.^{do} cuatrimestre de 2020

Última modificación: Tue Aug 4 14:36:17 2020 -0300

Facultad de Ingeniería (UBA)

Créditos

Para armar las presentaciones del curso nos basamos en:

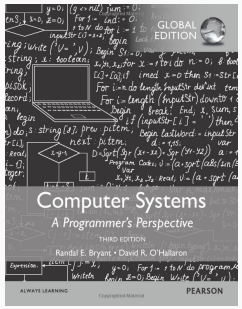

R. E. Bryant and D. R. O'Hallaron, *Computer systems: a programmer's perspective*, Third edition, Global edition. Boston Columbus Hoboken Indianapolis New York San Francisco Cape Town: Pearson, 2015.

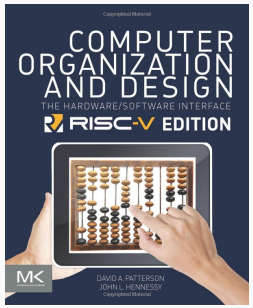

D. A. Patterson and J. L. Hennessy, *Computer organization and design: the hardware/software interface*, RISC-V edition. Cambridge, Massachusetts: Morgan Kaufmann Publishers, an imprint of Elsevier, 2017.

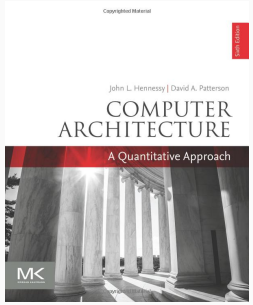

J. L. Hennessy and D. A. Patterson, *Computer architecture: a quantitative approach*. 2017.

Tabla de contenidos

Tabla de contenidos

Tabla de contenidos

Asignación de memoria

Declaración

> `T A[L];`

- Arreglo de largo `L` del tipo de dato `T`
- Asignado en una región de memoria *continua* de tamaño `L*sizeof(T)`

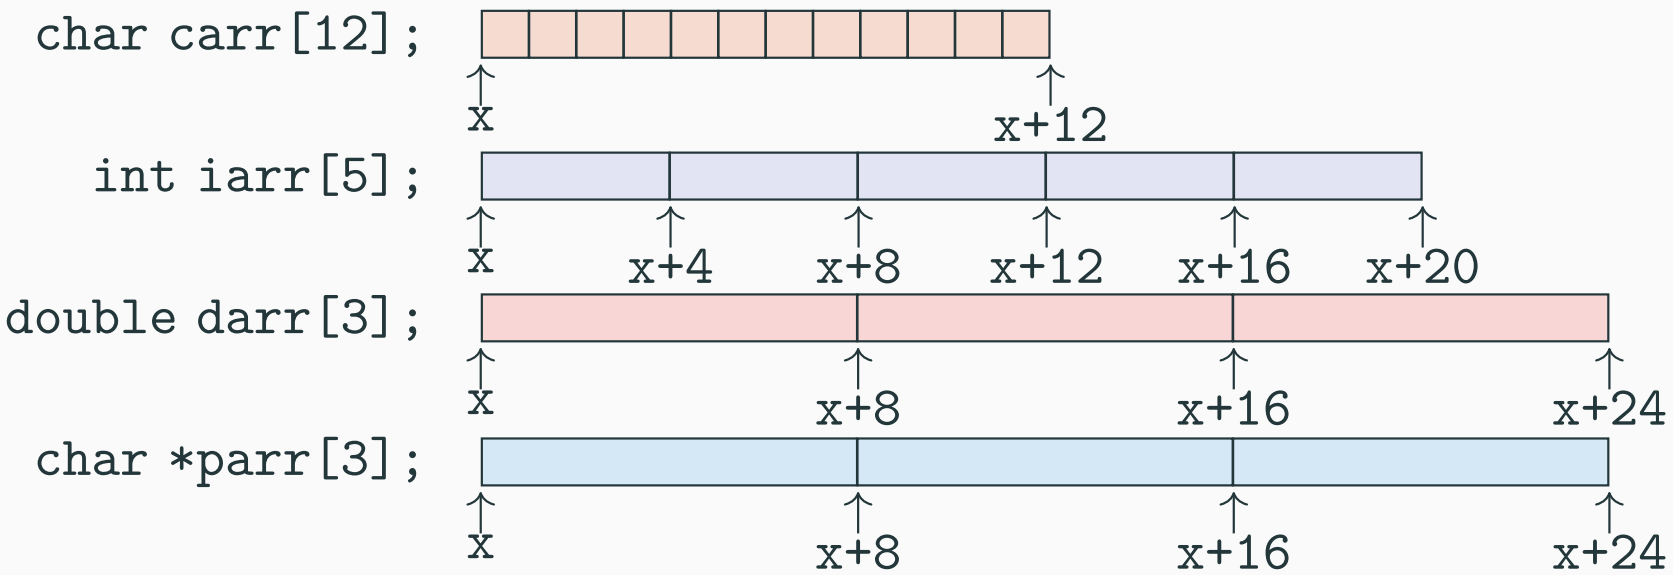

Acceso al arreglo

Declaración

- `T A[L]; // Arreglo de largo L del tipo de dato T`
- El símbolo `A` se puede usar como un punto al primer elemento del arreglo ⇒ su tipo es `T*`

`int iarr[5];`

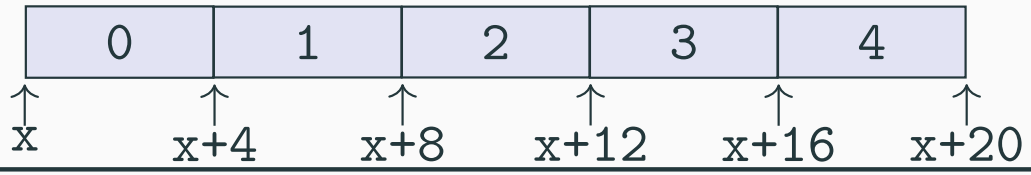

Referencia	Tipo	Valor	
`iarr[4]`	`int`	`4`	
`iarr`	`int *`	`x`	
`iarr + 1`	`int *`	`x + 4`	
`&iarr[2]`	`int *`	`x + 8`	
`iarr[5]`	`int`	`??`	
`*(iarr + 1)`	`int`	`1`	`//iarr[1]`
`iarr + i`	`int *`	`x + 4*i`	`//&iarr[i]`

Ejemplo

```
#define ZLEN 5
typedef int zip_dig[EZLN];

zip_dig cmu = {1, 5, 2, 1, 3};
zip_dig mit = {0, 2, 1, 3, 9};
zip_dig ucb = {9, 4, 7, 2, 0};
```

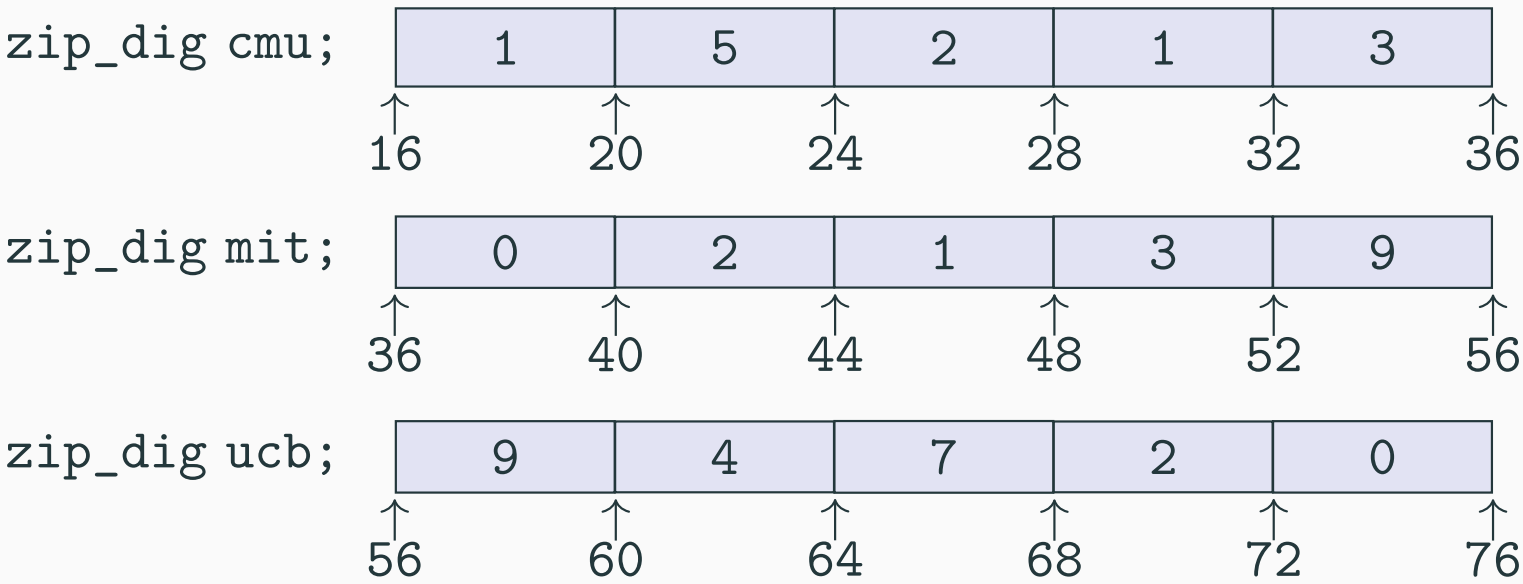

Ejemplo de acceso

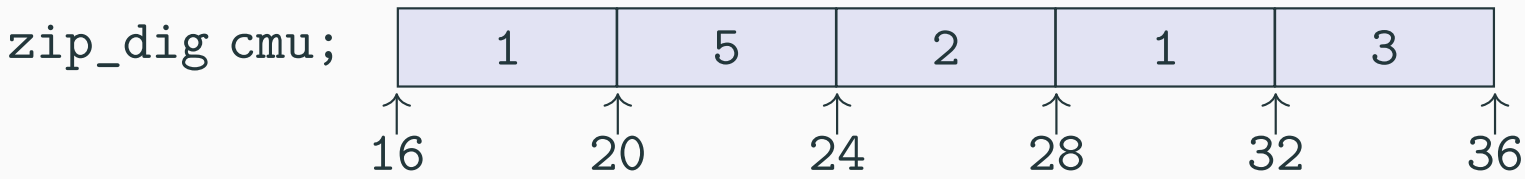

Lenguaje C

```
int get_digit(zip_dig z, int digit)
{
    return z[digit];
}
```

Lenguaje assembly (x86-64)

```
get_digit:
    # %rdi = z
    # %esi = digit
    movslq  %esi, %rsi
    movl    (%rdi,%rsi,4), %eax
    ret
```

- El registro `%rdi` contiene la dirección donde comienza el arreglo
- El registro `%rsi` (`%esi`) guarda el índice
- El dígito pedido se encuentra en `%rdi + 4*%rsi`
- Se usa la referencia `(%rdi,%rsi,4)`

Ejemplo de acceso en ciclos

```
void zinc(zip_dig z) {
  size_t i;
  for (i = 0; i < ZLEN; i++)
      z[i]++;
}
```

```
    leaq    20(%rdi), %rax
.L2:
    addl    $1, (%rdi)
    addq    $4, %rdi
    cmpq    %rax, %rdi
    jne     .L2
```

```
    xorl    %eax, %eax
.L2:
    incl    (%rdi,%rax,4)
    incq    %rax
    cmpq    $5, %rax
    jne     .L2
```

```
zinc:
    movl    $0, %eax
    jmp     .L2
.L3:
    leaq    (%rdi,%rax,4), %rcx
    movl    (%rcx), %esi
    leal    1(%rsi), %edx
    movl    %edx, (%rcx)
    addq    $1, %rax
.L2:
    cmpq    $4, %rax
    jbe     .L3
    rep ret
```

Tabla de contenidos

Arreglos multidimensionales (anidados)

Declaración

```
> T A[R][C];
```

- Arreglo 2D del tipo de dato `T`
- `R` filas, `C` columnas

Tamaño

```
R * C * sizeof(T) bytes
```

Disposición en memoria

- Memoria *continua*
- *Row-Major Ordering*

$$\begin{bmatrix} A[0][0] & \cdots & A[0][C-1] \\ A[1][0] & \cdots & A[1][C-1] \\ \vdots & \ddots & \vdots \\ A[R-1][0] & \cdots & A[R-1][C-1] \end{bmatrix}$$

```
int A[R][C];
```

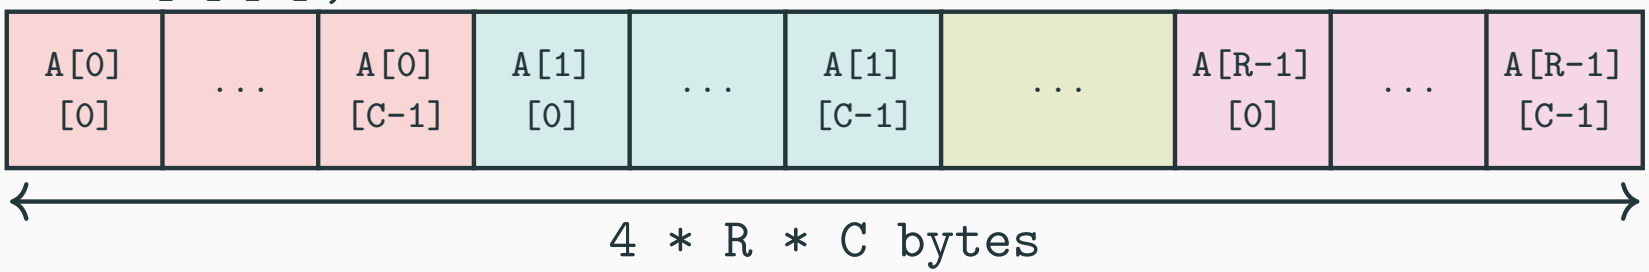

Ejemplo de arreglos anidados

```
#define PCOUNT 4
typedef int zip_dig[5];

zip_dig pgh[PCOUNT] = {
    {1, 5, 2, 0, 6},
    {1, 5, 2, 1, 3},  // a la vista es una matriz 2D
    {1, 5, 2, 1, 7},
    {1, 5, 2, 2, 1}};
```

`zip_dig pgh[4];`

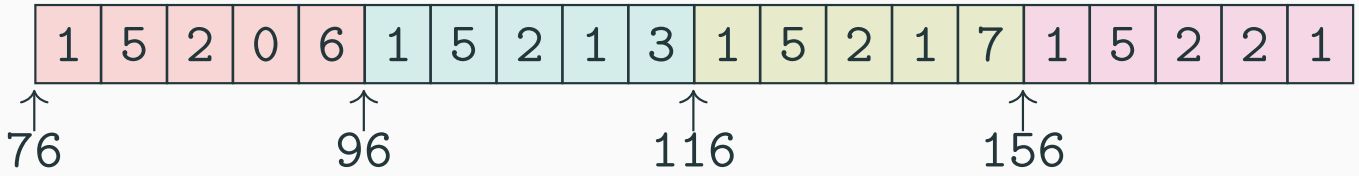

- `zip_dig pgh[4]` es equivalente a `int pgh[4][5]`
  - `pgh`: es un arreglo de 4 *elementos*
  - cada *elemento* es un arreglo de 5 `int`s

Acceso al arreglo

Vectores fila

- `A[i]` es un arreglo de `C` *elementos* del tipo de dato `T`
- Comienza en la dirección `A + i * (C * sizeof(T))`

```
int A[R][C];
```

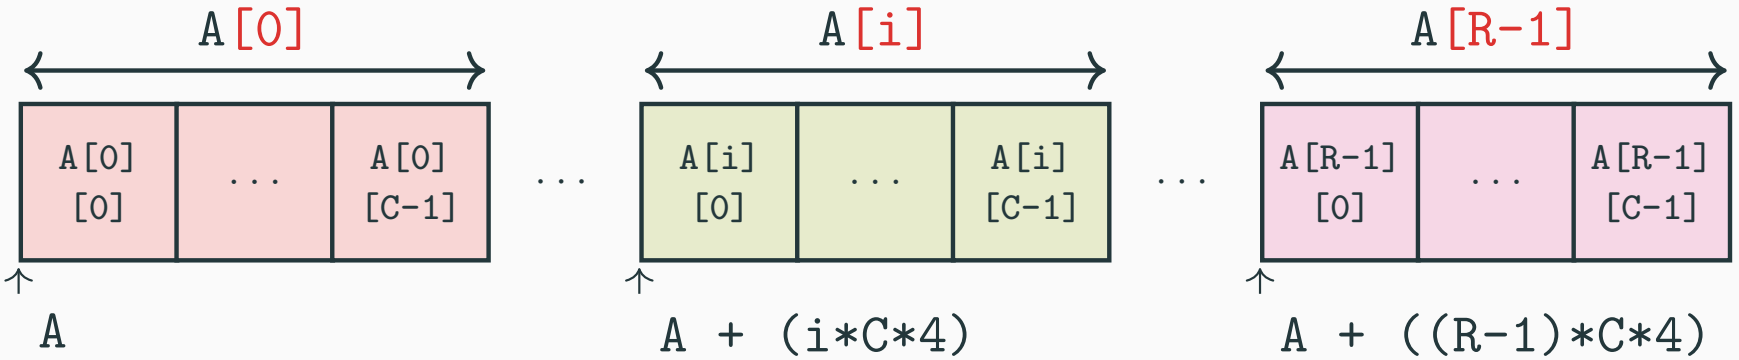

Ejemplo de acceso a arreglos anidados

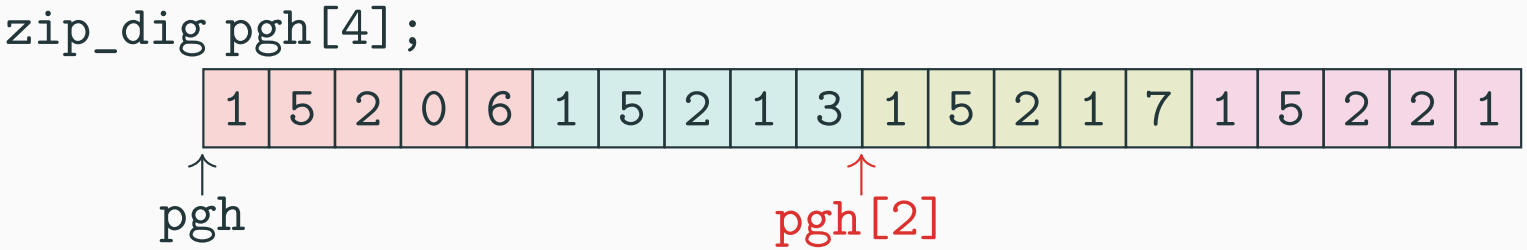


```
extern int pgh[4][5];

int * get_pgh_zip(unsigned long index) {
    return pgh[index]; // global
}
```

-Og

```
get_pgh_zip:
   leaq   (%rdi,%rdi,4), %rdx
   leaq   0(,%rdx,4), %rax
   addq   $pgh, %rax
   ret
```

-O1

```
get_pgh_zip:
   leaq   (%rdi,%rdi,4), %rax
   leaq   pgh(,%rax,4), %rax
   ret
```

En ambos casos se calcula **`pgh + 4*(index + 4*index)`**

Acceso a elementos del arreglo

Elementos del arreglo

- `A[i][j]` es un elemento tipo de dato `T`, tamaño `K` bytes
- Comienza en la dirección

  `A + i*(C*K)+j*K = A + (i*C + j) * K`

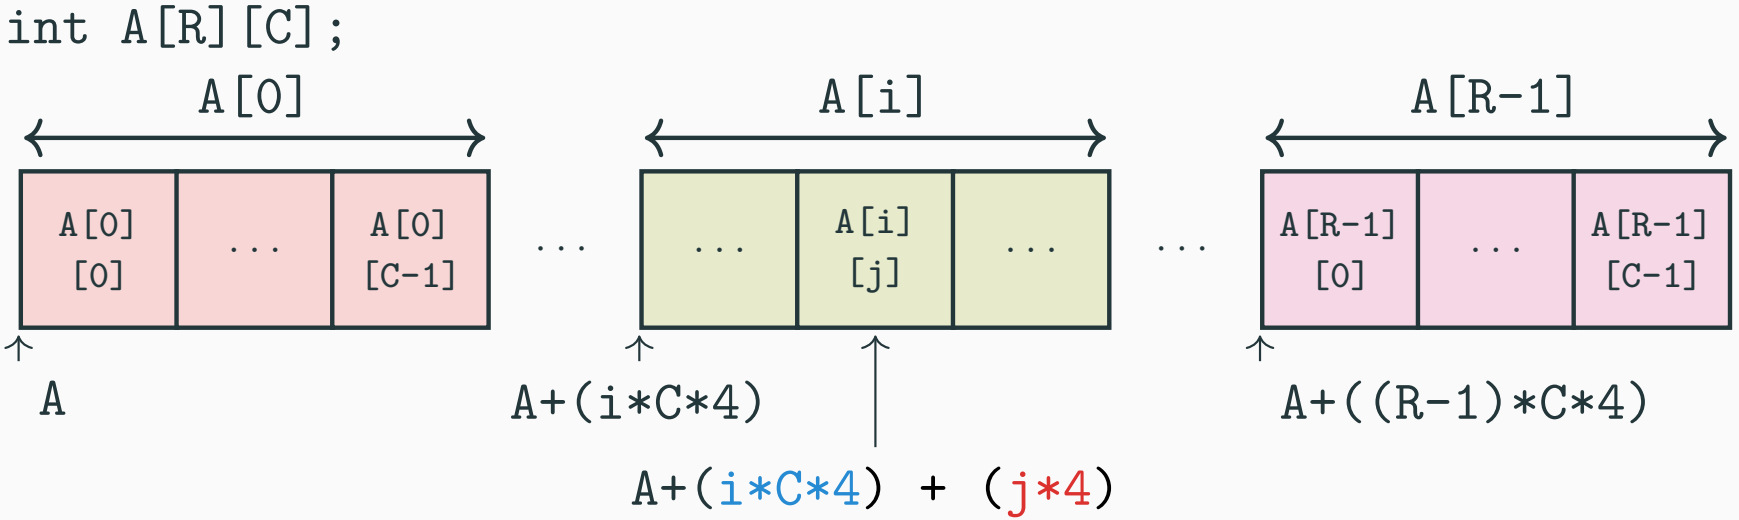

Ejemplo de acceso a elemento en arreglos anidados

```
zip_dig pgh[4];
```

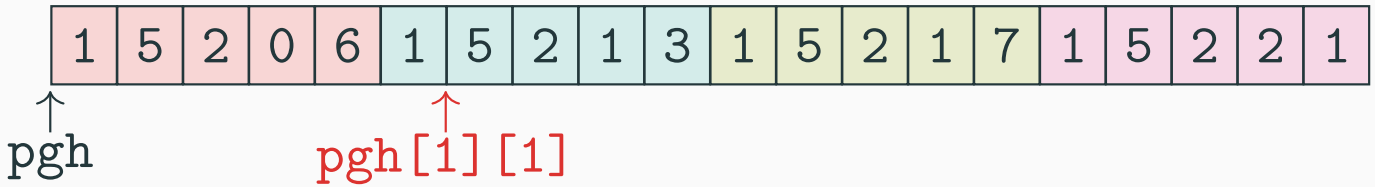


```
extern int pgh[4][5];

int * get_pgh_digit(unsigned long index, unsigned long digit) {
    return pgh[index][digit]; // global
}
```

-Og

```
get_pgh_digit:
   leaq    (%rdi,%rdi,4), %rax
   addq    %rax, %rsi
   movl    pgh(,%rsi,4), %eax
   ret
```

-O1

```
get_pgh_digit:
   leaq    (%rdi,%rdi,4), %rax
   addq    %rax, %rsi
   movl    pgh(,%rsi,4), %eax
   ret
```

El gcc genera: `pgh + 4*(index + 4*index + digit)`

Tabla de contenidos

Arreglos multinivel

```
zip_dig cmu = {1, 5, 2, 1, 3};
zip_dig mit = {0, 2, 1, 3, 9};
zip_dig ucb = {9, 4, 7, 2, 0};
```

```
#define UCOUNT 3
int *univ[UCOUNT] = {mit, cmu, ucb};
```

- `univ` es un arreglo de 3 *elementos*
- cada elemento es un puntero
- cada puntero apunta a un arreglo de `int`s

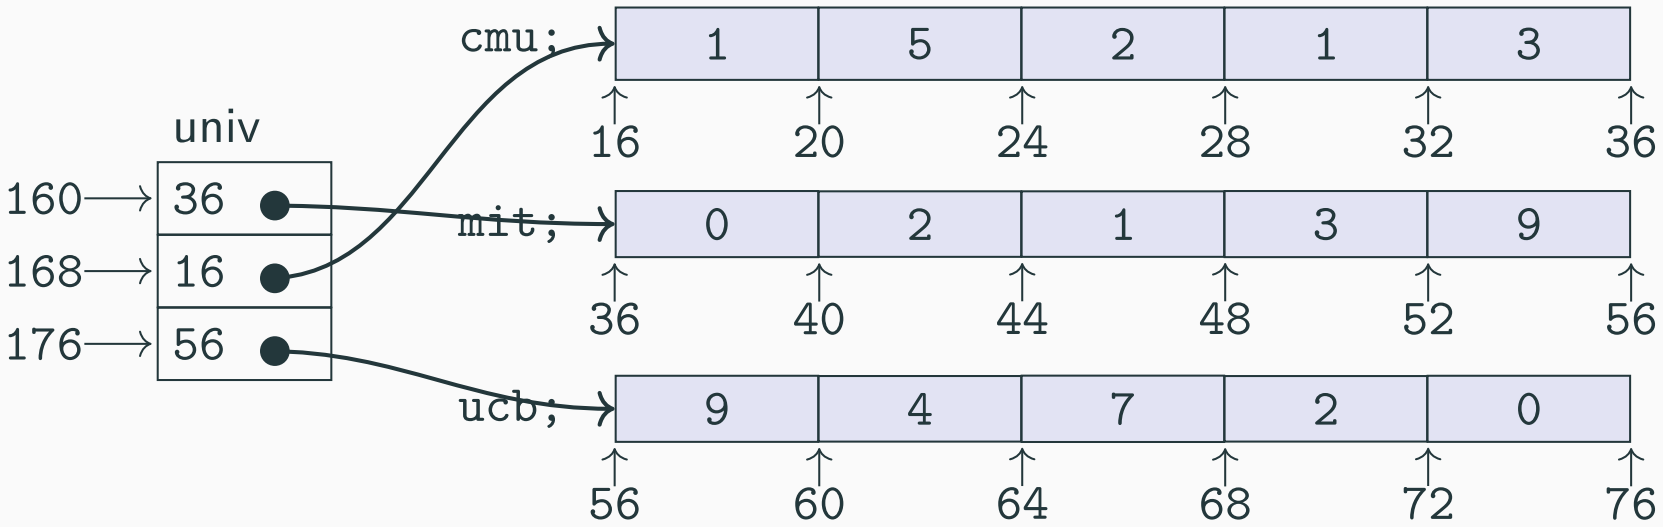

Ejemplo de acceso a elemento en arreglos multinivel

```
int get_univ_digit
  (size_t index, size_t digit)
{
    return univ[index][digit];
}
```

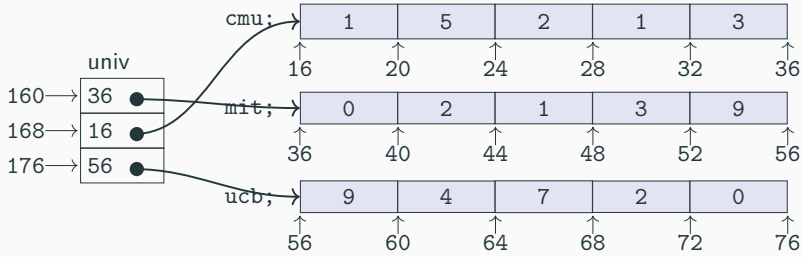

-Og

```
get_univ_digit:
   salq   $2, %rsi
   addq   univ(,%rdi,8), %rsi
   movl   (%rsi), %eax
   ret
```

-O1

```
get_univ_digit:
   movq   univ(,%rdi,8), %rax
   movl   (%rax,%rsi,4), %eax
   ret
```

- Calcula: `Mem[Mem[univ + 8*index] * 4*digit]`
- Hace 2 accesos a memoria, 2 lecturas
  - Primero obtiene el puntero a la fila
  - La dirección de memoria del elemento **depende** del valor guardado `univ[index]`

Tabla de contenidos

Matrices NxN

- Dimensiones fijas
  - Se conoce N en tiempo de compilación
- Dimensiones variables, indexado explícito
  - El arreglo unidimensional A es fijo
- Dimensiones variables, indexado implícito
  - Soporte desde C99, opcional desde C11

```c
#define N 16
typedef int mfija[N][N];
int mfija_ij(mfija A, size_t i, size_t j) {
    return A[i][j];
}
```

```c
#define IDX(n, i, j) ((i)*(n)+(j))
int mvar_exp(size_t n, int *A,
             size_t i, size_t j) {
    return A[IDX(n, i, j)];
}
```

```c
int mvar_imp(size_t n, int A[n][n],
             size_t i, size_t j) {
    return A[i][j];
}
```

Ejemplo de acceso a matrices de tamaño variable

- **Elementos del arreglo**
  - `size_t n;`
  - `int A[n][n]`
  - `A[i][j]` en `A + i*(C*K) + j*K`
  - C = n, K = 4
  - Sí o sí se debe hacer multiplicación de enteros (`imulq`)

```
int mvar_imp(size_t n, int A[n][n], size_t i, size_t j) {
    return A[i][j];
}
```

```
# n en %rdi, A en %rsi, i en %rdx, j en %rcx
mvar_imp:
   imulq    %rdi, %rdx             # n*i
   leaq     (%rsi,%rdx,4), %rax    # A + 4*n*i
   movl     (%rax,%rcx,4), %eax    # A + 4*n*i + 4*j
   ret
```

Tabla de contenidos

Tabla de contenidos

Representación de estructuras

```
struct rec {
    int a[4];
    size_t i;
    struct rec * next;
} r;
```

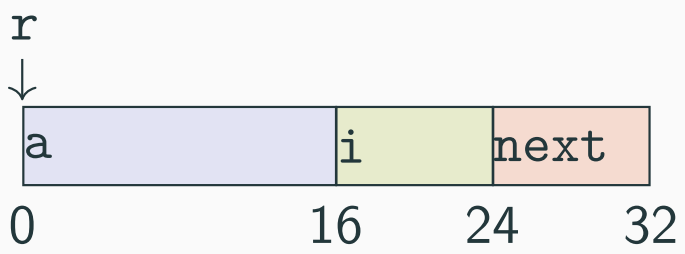

- La estructura se representa como un bloque de memoria
  - Lo suficientemente grande como para contener todos los campos
- Los campos se ordenan **de acuerdo a la declaración**
  - Incluso si otro ordenamiento brinda una representación más compacta
- El compilador determina el tamaño total y los *offsets* de los campos (y los recuerda)
  - En el lenguaje de máquina no se tiene conocimiento de las estructuras en el código fuente

Tabla de contenidos

Obtención de punteros a los miembros

```
struct rec {
    int a[4];
    size_t i;
    struct rec * next;
} r;
```

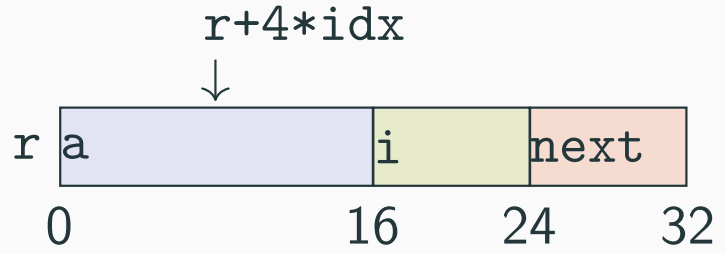

- Sabiendo cómo obtener el puntero al dato, obtener el dato es trivial
  - El *offset* de cada miembro de la estructura se determina en tiempo de compilación
  - Sabemos que `&a = &r`, entonces:
    - `r + 4*idx`

```
int *get_ap(struct rec * r,
    size_t idx) {
    return &r->a[idx];
}
```

```
get_ap:
   leaq   (%rdi,%rsi,4), %rax
   ret
get_ip:
   leaq   16(%rdi), %rax
   ret
get_nextp:
   leaq   24(%rdi), %rax
   ret
```

Iterando con la estructura I

```c
long largo(struct rec *r) {
    long len = 0L;
    while (r) {
        len++;
        r = r->next;
    }
    return len;
}
```

```c
struct rec {
    int a[4];
    size_t i;
    struct rec * next;
} r;
```

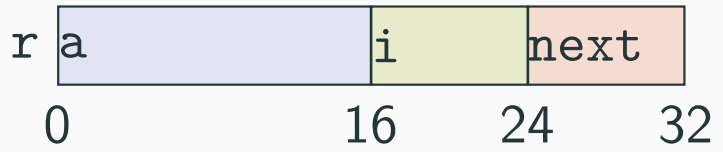

Código assembly

```
    movl    $0, %eax
    jmp     .L2
.L3:
    addq    $1, %rax
    movq    24(%rdi), %rdi
.L2:
    testq   %rdi, %rdi
    jne .L3
```

Iterando con la estructura II

```
void set_a(struct rec *r,
           int v) {
    while (r) {
        size_t i = r->i;
        r->a[i] = v;
        r = r->next;
    }
}
```

```
struct rec {
    int a[4];
    size_t i;
    struct rec * next;
} r;
```

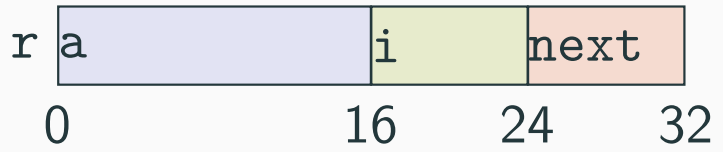

Código assembly

```
    jmp .L5
.L6:
    movq    16(%rdi), %rax
    movl    %esi, (%rdi,%rax,4)
    movq    24(%rdi), %rdi
.L5:
    testq   %rdi, %rdi
    jne .L6
```

Tabla de contenidos

Alineamiento de estructuras

Datos no alineados

```
struct st_a {
    char c;
    int i[2];
    double v;
} *p;
```

- Todos los datos se guardan "pegados", independientemente de tamaños.

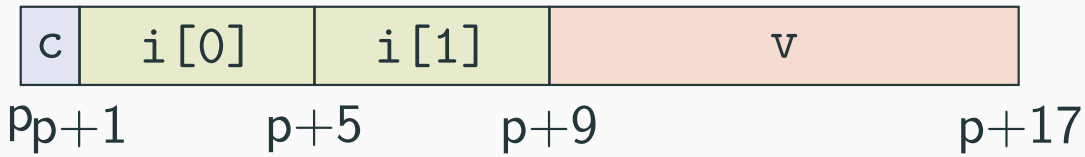

Datos alineados

- Si el tipo de dato es de B bytes, entonces su dirección debe ser múltiplo de B.

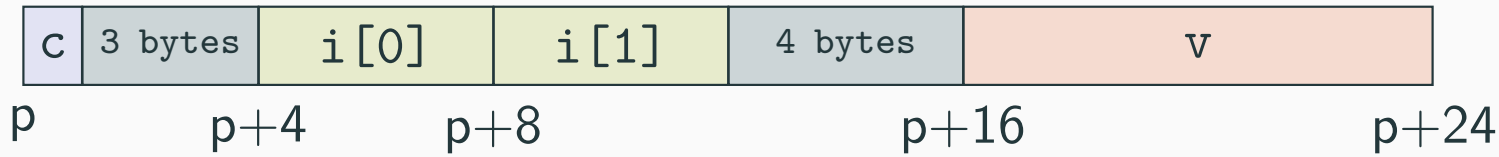

Principios del alineamiento

- Alineación de datos
  - Si el dato requiere `B` bytes
  - La dirección donde comienza debe ser múltiplo de `B`
  - Es requisito en algunas arquitecturas; aconsejado en x86-64
- Motivación
  - La memoria se accede de a pedazos (alineados) de 4 u 8 bytes (dependiente del sistema)
    - Es ineficiente cargar o guardar datos que se extienden por más de una línea de cache (64 bytes)
      Intel recomienda no superar los límites de 16 bytes.
    - La memoria virtual es más complicada cuando los datos abarca 2 páginas (páginas: 4 KB)
- El compilador
  - Inserta huecos en la estructura para asegurar el correcto alineamiento de los datos

Casos específicos de alineamiento

x86-64

- 1 byte: `char`
  - no tiene restricciones en la dirección
- 2 byte: `short`
  - el bit más bajo de la dirección debe ser 0_2
- 4 byte: `int, float`
  - los 2 bits más bajos de la dirección deben ser 00_2
- 8 byte: `double, long char *, ...`
  - los 3 bits más bajos de la dirección deben ser 000_2

Requerimientos de alineamiento en estructuras

Internamente

- Se deben satisfacer los requerimientos de cada elemento

```
struct st_a {
    char c;
    int i[2];
    double v;
} *p;
```

Ubicación global de la estructura

- Sea **K** el requerimiento de alineamiento de la estructura, donde **K** es el máximo requerimiento de los elementos internos
- La dirección y el largo de la estructura deben ser múltiplos de **K**

Ejemplo

- **K** $= 8$ debido al `double` ; **K** $\leq$ `sizeof(struct st_a)`

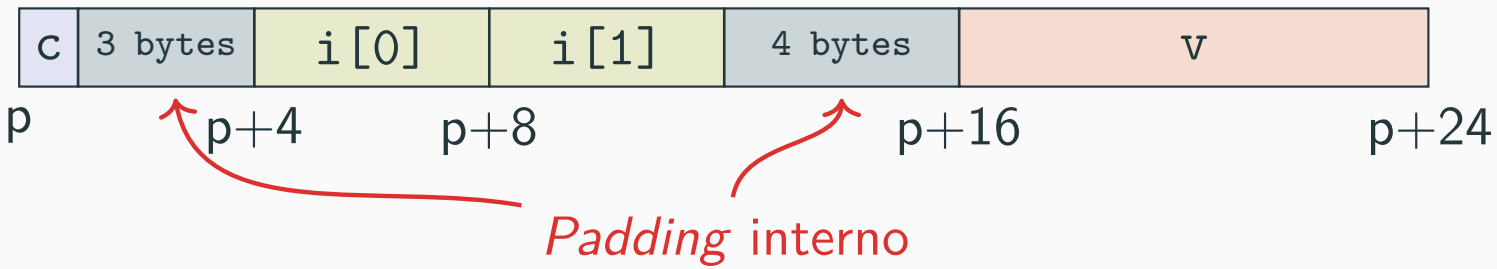

Cumpliendo con los requisitos de alineamiento I

- Se debe cumplir con los requisitos de alineamiento interno y con el alineamiento global de la estructura con el requerimiento **K** de alineamiento máximo de sus elementos

```
struct st_b {
    double v;
    char c;
    int i[2];
} *p;
```

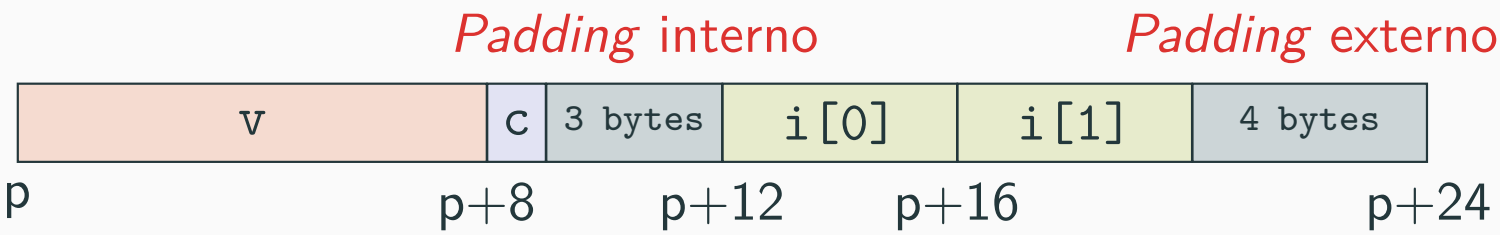

El estándar garantiza que nunca hay *padding* al inicio de una estructura

Cumpliendo con los requisitos de alineamiento II

- Se debe cumplir el alineamiento global de la estructura con el requerimiento **K** de alineamiento máximo de sus elementos

```
struct st_c {
    double v;
    int i[2];
    char c;
} *p;
```

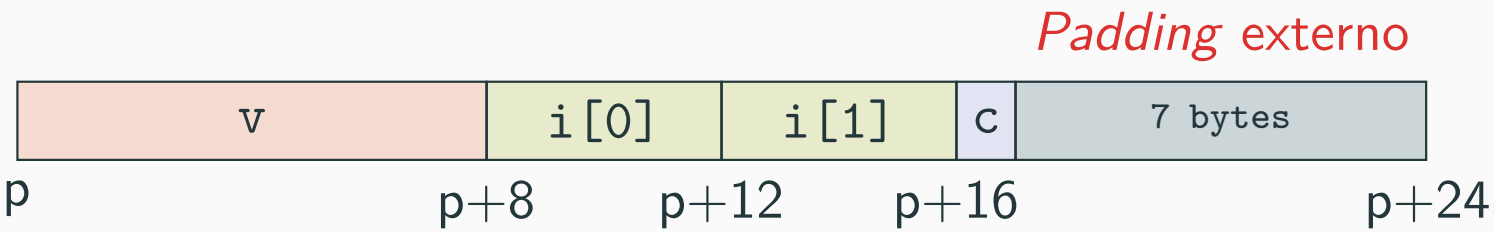

Arreglos de estructuras

- Aquí se ve por qué es necesario el *padding* externo.

```
struct st_c {
    double v;
    int i[2];
    char c;
} a[10];
```

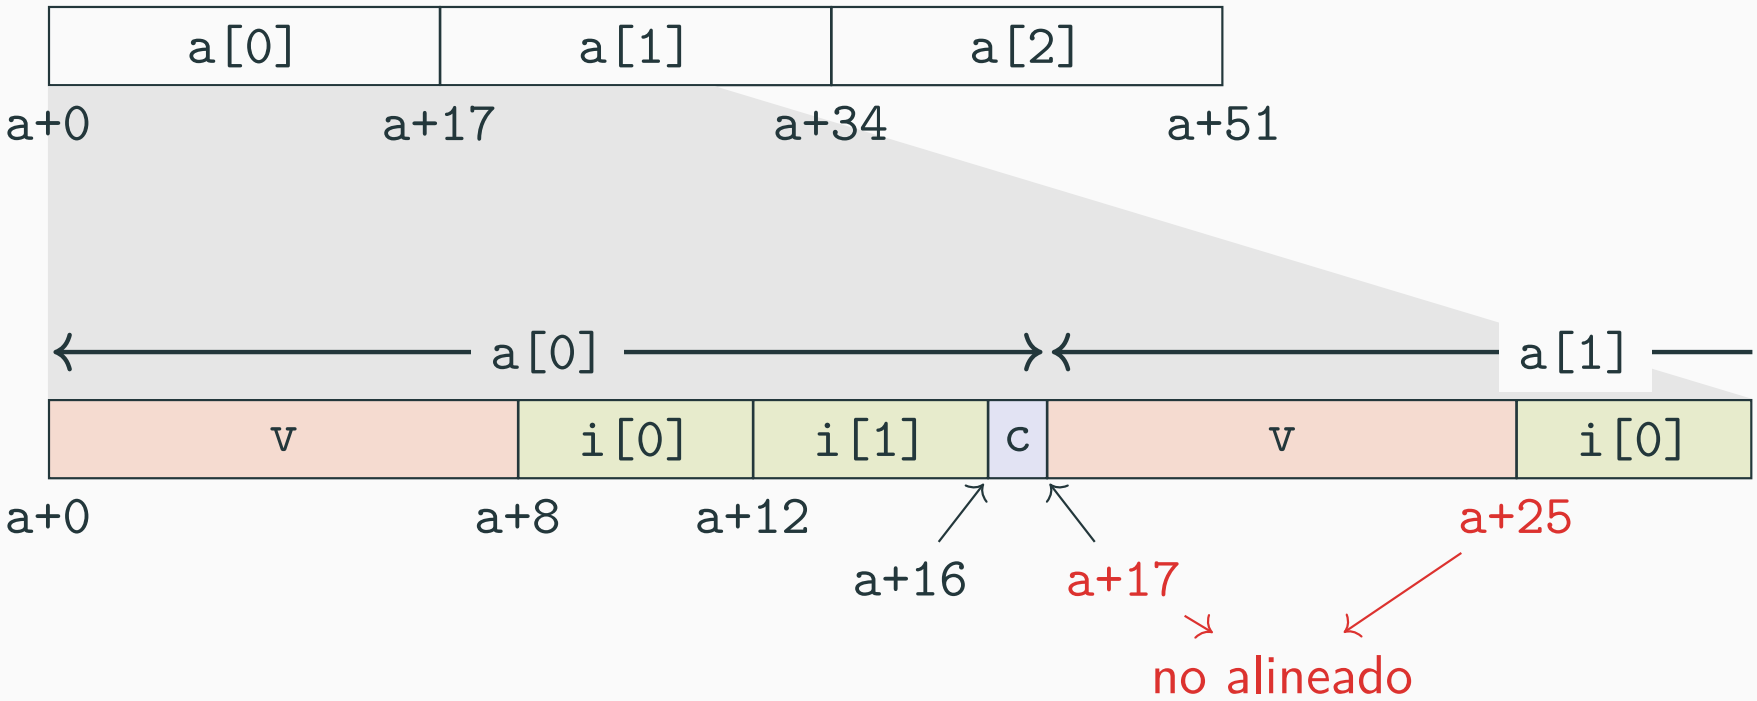

Arreglos de estructuras

- Se deben cumplir los mismos requisitos que para una estructura, para cada elemento del arreglo.
- Con las reglas vistas hasta ahora, el item anterior se cumple siempre.

```
struct st_c {
    double v;
    int i[2];
    char c;
} a[10];
```

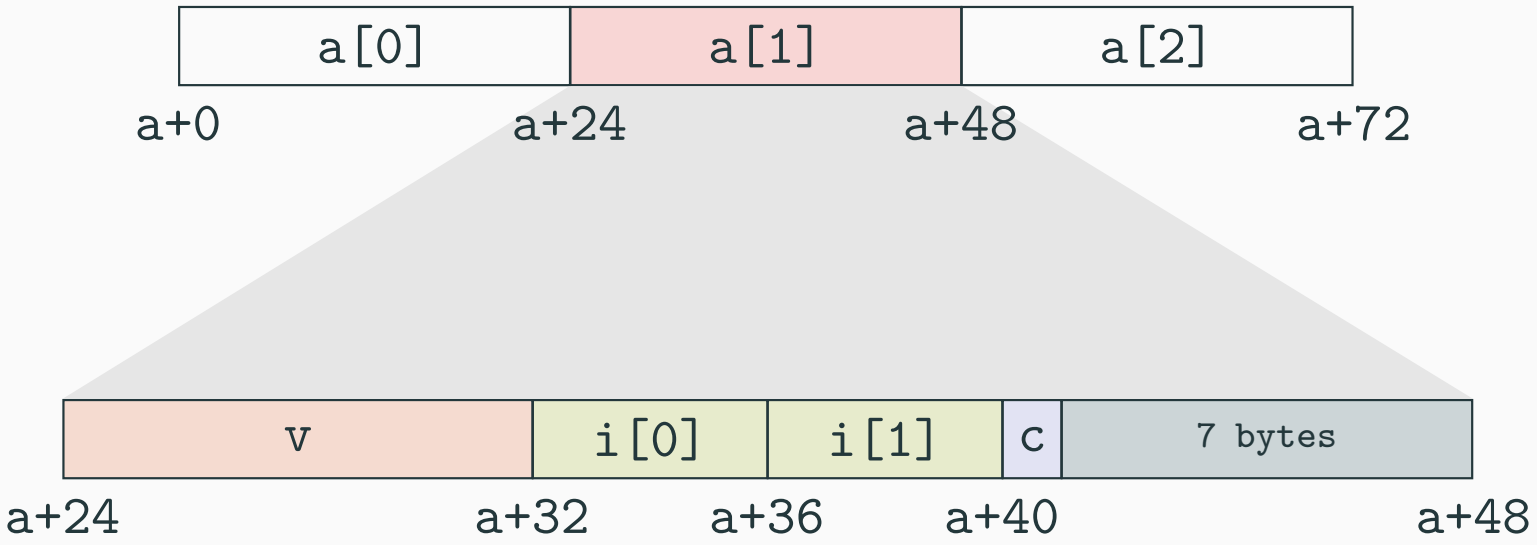

Acceso a los miembros dentro del arreglo

- Calcular la posición del elemento en el arreglo a: 12*idx
  - 12 es el `sizeof` de `struct st_d`
- s2 está a un *offset* 8 en la estructura

```
struct st_d {
    short s1;
    float f;
    short s2;
} a[10];
```

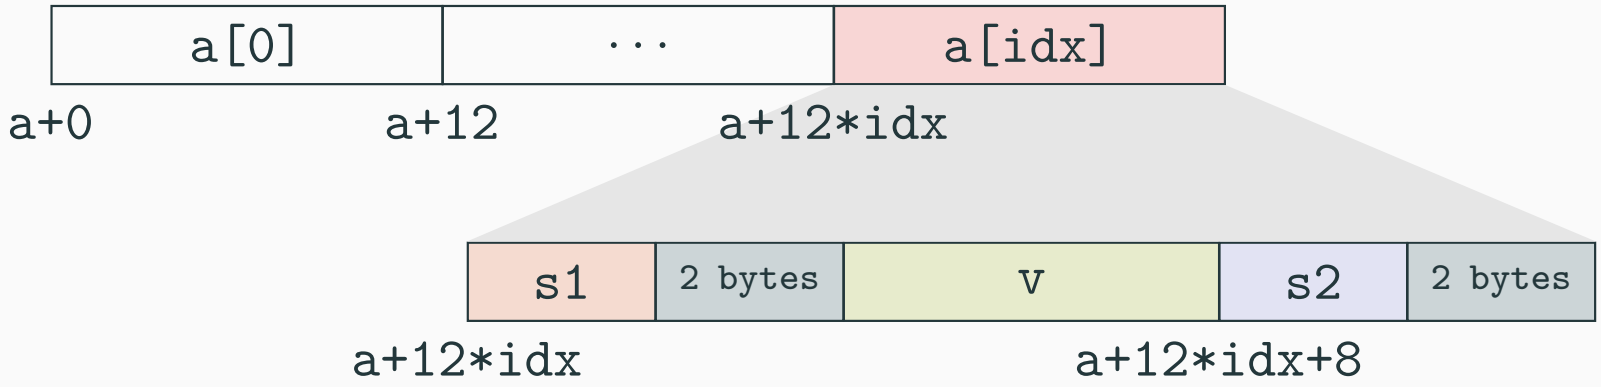


```
short get_s2(unsigned long
    idx) {
   return a[idx].s2;//global
}
```

```
get_s2:
    leaq    (%rdi,%rdi,2), %rax
    movzwl  a+8(,%rax,4), %eax
    ret
```

Asignación óptima

- Simplemente hay que ordenar los datos en la estructura en orden decreciente de tamaño (`sizeof`)

No óptima

```
struct st_u {
    char c;
    int i;
    char d;
} *p;
```

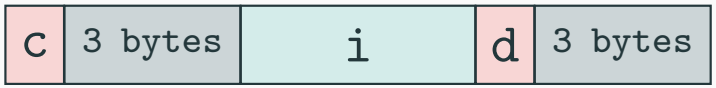

12 bytes

Óptima

```
struct st_o {
    int i;
    char c;
    char d;
} *p;
```

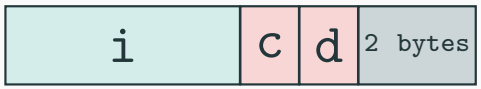

8 bytes

Tabla de contenidos

Historia

- Punto Flotante (FP) en x87
  - Arcáico (1977 hasta MMX)
- MMX (Intel P5, 1997)
  - Primeras SIMD, pero **no** soporta FP...
  - ...de hecho, puede corromper el stack de FP
  - Reutiliza parte del x87
- 3DNow! (AMD K6-2, 1998)
  - Extiende MMX
  - Agrega la capacidad de trabajar con FP (32 bits)
- Serie SSE (Streaming SIMD Extensions)
  - Agrega soporte de FP a MMX
  - Agrega los registros `xmm`n ($n = 0, \ldots, 7$) de 128 bits
- Serie AVX (Advanced Vector Extensions)
  - Extiende los registros `xmm` a 256 y 512 bits (`ymm` y `zmm`)
  - Es el más avanzado a la fecha

Programación con SSE4: registros `XMM`

16 registros de enteros de 1 byte

8 registros de enteros de 2 bytes

4 registros de enteros de 4 bytes

4 registros de `floats` de 4 bytes (precisión simple)

2 registros de `doubles` de 8 bytes (precisión doble)

1 registro de FP en precisión simple

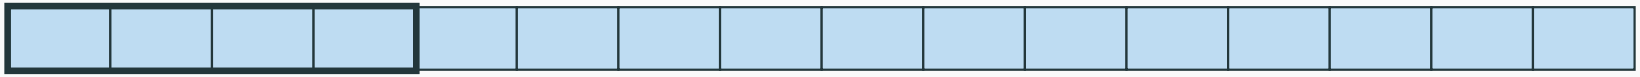

1 registro de FP en precisión doble

Operaciones escalares y SIMD

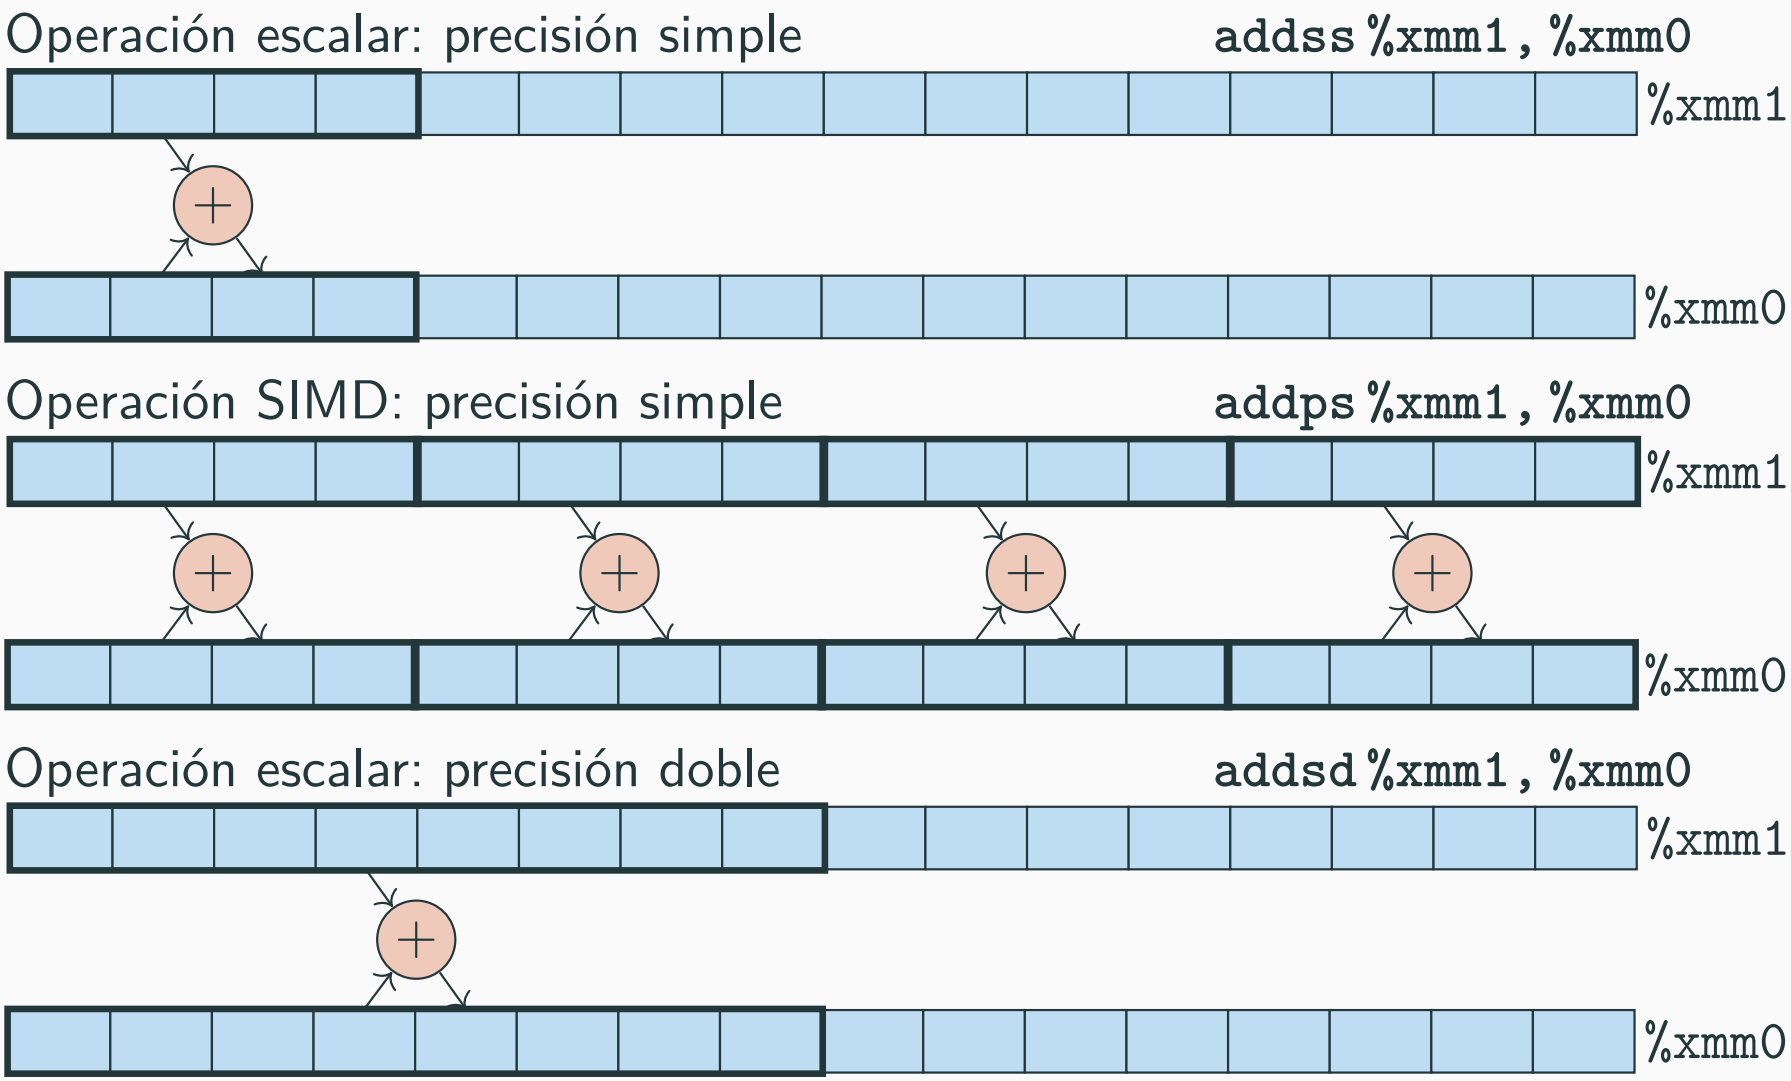

Calling conventions de punto flotante

- Los argumentos se pasan en `%xmm0`, `%xmm1`, ...
- El resultado se retorna en `%xmm0`
- Todos los registros XMM son **caller-saved**

```
float fadd(float x, float y){
    return x + y;
}
```

```
double dadd(double x, double y){
    return x + y;
}
```

```
fadd:
    addss    %xmm1, %xmm0
    ret
```

```
dadd:
    addsd    %xmm1, %xmm0
    ret
```

Referenciando memoria con punto flotante

- Los argumentos enteros (y punteros) se pasan en registros comunes (`%rdi`, `%rsi`, ...)
- Los argumentos de punto flotante se pasan en los registros XMM
- Hay instrucciones separadas para mover datos entre registros XMM, y entre la memoria y los registros XMM

```
double dincr(double *p, double v){
    double x = *p;

    *p = x + v;
    return x;
}
```

```
dincr:
    movapd   %xmm0, %xmm1    # Guarda v en %xmm1
    movsd    (%rdi), %xmm0   # Desreferencia %rdi a %xmm0
    addsd    %xmm0, %xmm1    # Suma y guarda en %xmm1
    movsd    %xmm1, (%rdi)   # Guarda %xmm1 en *p
    ret                      # retorna %xmm0
```

Licencia del estilo de beamer

Obtén el código de este estilo y la presentación demo en

`github.com/pamoreno/mtheme`